

PARCIAL INGENIRIA DE DATOS

Momento 1 :

Repo juan Esteban https://github.com/jecortes200/INGENIEIRIA-DE-DATOS/tree/c1c0f276aa408f2b44157491ab9ea2dc5e08bfe5/primer_corte/parcial_1

A	B	C	D	E	F	G	H	I	J	K
fuentes	descripción	frecuencia_actualizac	volumen_diario_regis	registra_inicio_viaje	registra_fin_viaje	duplicados_errores_digit	reintenta_envio_sin_senal			
App movil VeloBog	Evento generado cuando el tiempo real		4820 SI		NO	bajo	no	no		
Candados IoT	Telemetria del candado ele tiempo real		9160 SI		SI	alto	no	SI		
Excel de Operaciones	Planilla que la coordinado 1 vez al dia		410 SI		SI	bajo	si	no		

Momento 1 · Sala de servidores

10 minutos | Corredor 1 | 15 puntos | Insumo: M1_inventario_fuentes.csv

Entraste a la sala de servidores de VeloBog y encontraste tres tableros desordenados. Para abrir la puerta del siguiente cuarto hay que resolverlos.

1.1 Ordena el flujo · 4 puntos

Numera de 1 a 7 según el ciclo de vida del dato:

Etapas	N°	Etapas	N°
Visualización y consumo	2	Modelado y análisis	5
Almacenamiento en el data warehouse	6	Generación del dato en el origen	1
Ingesta desde las fuentes	3	Transformación y limpieza	4
Gobierno y monitoreo continuo	7		

1.2 Empareja el rol con la frase · 4 puntos

Rol	Letra + número	Frase que diría en una reunión
A. Ingeniero de datos	A 1	1. «Necesito que el reporte de ocupación esté listo cada lunes a las 7 a.m.»
B. Analista de datos	B 4	2. «El pipeline se cayó anoche, la partición del 14 no cargó.»
C. Científico de datos	C 2	3. «Voy a entrenar un modelo para predecir la demanda por estación.»
D. Stakeholder de negocio	D 3	4. «Con estos gráficos se ve que los martes cae el uso un 12 %.»

1.3 Verdadero o falso, con justificación de una línea · 4 puntos

Sin justificación la respuesta no puntúa.

Afirmación	V/F	Justificación
a. Un dato con formato correcto es automáticamente un dato de calidad.		
b. El EDA se hace después de tener el modelo entrenado.		
c. En un pipeline ELT la transformación ocurre dentro del sistema de destino.	✓	ya que
d. Los requerimientos no funcionales son opcionales porque no describen funciones del sistema.	✓	Porque son requerimientos que no necesitamos durante el Proyecto

1.4 Reto de lógica · 3 puntos

Abre M1_inventario_fuentes.csv. Hay tres fuentes: App móvil, Candados IoT y Excel de Operaciones. Dos celdas están marcadas con «?» y debes deducirlas con estas pistas:

- La fuente que actualiza en tiempo real no es la que tiene errores de digitación.

- La fuente con más registros duplicados es la que reintenta el envío cuando pierde señal.
- La app registra el inicio del viaje, pero no el final.

Pregunta: ¿cuál es la única fuente confiable para saber a qué hora terminó un viaje, y por qué esa misma fuente exige una deduplicación obligatoria en el pipeline? Responde en máximo tres renglones.

Entregable: hoja de respuestas del momento 1 con el nombre del corredor.

Juan Esteban Cárter

El conchito Lot ya que la frecuencia es a tiempo real, se

Momento 2 :

Repo mariana: <https://github.com/marialejaussa/Ingenieria-de-datos-/tree/b148a453f423366db00f82f14e7ebb1aab13b301/Parcial%20Practico%201>

#	Fila / columna	Problema detectado	Tipo	Regla de transformación propuesta
1	2	La fila está repetida	Duplicado	Eliminar
2	4/2	Costo vacío	NULO	Eliminar
3	3/2	Duración negativa	Inconsistencia	Imputar
4	2/5	Estos en formato de texto	Formato	Cambiar el tipo de dato
5	4/1	El destino es el mismo que el origen	Inconsistencia	Eliminar
6	8/1	No muestra la edad en un solo número	Formato	Imputar
7	7/8	Costo negativo	Violación de regla de negocio	Imputar
8	10/3	Texto no válido	Formato	Cambiar el tipo

Tipos válidos: duplicado - nulo - formato - inconsistencia - valor atípico - violación de regla de negocio.

Ojo: dos problemas del anexo no se ven mirando una sola celda. Se detectan comparando columnas entre sí.

2.2 Diseño del pipeline - 9 puntos

Escribe el pipeline en pseudocódigo o SQL, con las tres fases rotuladas:

- [E] EXTRACT: de dónde, con qué frecuencia y cómo detectas registros nuevos.
- [T] TRANSFORM: mínimo cinco operaciones, en el orden correcto.
- [L] LOAD: destino, granularidad (¿una fila por qué cosa?) y estrategia de carga.

Debes justificar por qué la deduplicación va antes o después de la conversión de tipos.

2.3 Decisión de ingeniería - 6 puntos

Responde y argumenta en máximo cuatro renglones cada una:

- a. Encontraste 47 viajes con duración negativa. Tienes tres opciones: eliminar, imputar o cuarentena. ¿Cuál eliges y cuál es el costo de las otras dos?
- b. El campo estación de origen viene escrito de seis formas distintas para la misma estación. ¿Lo resuelves con normalización de texto o con una tabla maestra de estaciones? Sustenta.

Entregable: tabla de auditoría más pipeline escrito

→ Si la duración es negativa, la opción que tomaría sería imputar, teniendo en cuenta la duración de viajes iguales o similares.

→ Normalización de texto, para tener un tipo de formato para el campo de estación de origen.

-*- coding: utf-8 -*-

"""Momento_2.ipynb

Automatically generated by Colab.

Original file is located at

<https://colab.research.google.com/drive/1GsUzwiNjn9scIPr3xc1Ku3ldGpT4TL-8>

"""

```
df = pd.read_csv('/content/M2_viajes_agosto.csv')
```

```
import pandas as pd
```

```

# Estandarizar nombre de la estacion
df['estacion_origen'] = df['estacion_origen'].str.title()
df['estacion_destino'] = df['estacion_destino'].str.title()

# Convert date columns to datetime, coercing errors to NaT
df['fecha_inicio'] = pd.to_datetime(df['fecha_inicio'], errors='coerce', dayfirst=False)
df['fecha_fin'] = pd.to_datetime(df['fecha_fin'], errors='coerce', dayfirst=False)

display(df.head())

display(df.info())

```

"""### Manejo de Valores Faltantes y Conversión de Tipos de Datos

El paso anterior nos mostró que hay valores faltantes en varias columnas y que `costo` y `edad\_usuario` siguen siendo de tipo 'object'. Procederemos a:

1. **Identificar valores faltantes:** Contar los valores `NaN` por columna.
2. **Limpiar y convertir `costo`:** Convertir a tipo numérico y corregir valores negativos o inconsistentes.
3. **Limpiar y convertir `edad\_usuario`:** Convertir a tipo numérico y tratar posibles errores.

"""

```

print('Valores faltantes por columna:')
display(df.isnull().sum())

```

```
# Convertir "costo" a numérico.
```

```
# Asumiremos que los valores "object" son strings de números y los convertiremos a float.
```

```
df["costo"] = pd.to_numeric(df["costo"], errors="coerce")
```

```
# Corregir costos negativos: asumiendo que un costo negativo es un error y debería ser positivo.
```

```
df["costo"] = df["costo"].abs()
```

```
# Convertir 'edad_usuario' a numérico.
```

```
df['edad_usuario'] = pd.to_numeric(df['edad_usuario'], errors='coerce')
```

```
display(df.head())
```

```
display(df.info())
```

```
"""### Cálculo de Duración del Viaje
```

Ahora que `fecha\_inicio` y `fecha\_fin` son de tipo `datetime`, podemos calcular la duración exacta de cada viaje en minutos.

```
"""
```

```
df['duracion_calculada_min'] = (df['fecha_fin'] - df['fecha_inicio']).dt.total_seconds() / 60
```

```
display(df.head())
```

```
display(df.info())
```

Momento 3:

Repo de José Catral:

https://github.com/Davidx34/Ingenieria_de_datos/tree/cc7e66919307d97722f50aa2106fcf3be850719e/trabajos_de_clase/corte_1/parcial_practico1

Momento 3 · El tablero miente

15 minutos | Corredor 3 | 20 puntos | Insumos: los tres archivos M3 (Anexo B)

El gerente muestra en el comité un tablero que dice: «el viaje promedio dura 34 minutos, vamos excelente». Tú sospechas.

3.1 Estadística que decide · 8 puntos

- a. Calcula la media y la mediana de la duración con los datos del Anexo B.1. Muestra el procedimiento. *La media es 54.2*
- b. Explica en dos renglones por qué difieren tanto y cuál de las dos debe ir en el tablero del gerente.
- c. Aplica la regla del rango intercuartílico: identifica qué valores quedan fuera de $[Q1 - 1.5 \cdot IQR ; Q3 + 1.5 \cdot IQR]$. *Valores Extremos por eso me da*

3.2 Lectura de distribución y nulos · 6 puntos

- a. La columna edad_usuario tiene 18 % de nulos y todos pertenecen a usuarios registrados antes de 2023. ¿Ese nulo es aleatorio o sistemático? ¿Qué implica para tu análisis?
- b. Observa la tabla de viajes por franja horaria. Describe la forma de la distribución y da una hipótesis de negocio que la explique. *de 6 a 8 la mañana y de la noche aumentan los viajes debido que la gente entra y sale del trabajo*

3.3 De hallazgo a acción · 6 puntos

Escribe tres hallazgos en el formato exigido por la firma:

Hallazgo	Evidencia (cifra)	Riesgo o pregunta que abre	Acción recomendada
1. <i>Valores extremos</i>	<i>Media 54.2</i>		
2.			
3.			


Trampa: al menos uno de tus hallazgos debe advertir que el dato todavía no permite concluir algo, y explicar qué dato faltaría.

Entregable: cálculos más tabla de hallazgos.

Las respuestas de cada uno están en cada libro de excel con sus cálculos, gráficas e interpretación

id_viaje	duracion_min	Media	54,2	
2001	8			
2002	11	Mediana	18	Debe ir solo la mediana pues la media se ve distorsionada por los valores atípicos altos.
2003	12			
2004	12			
2005	14			
2006	15		15	
2007	17			
2008	18	Rango intercuartil	15	
2009	20	Bigote inferior	-10,5	
2010	22	Bigote superior	49,5	
2011	24			
2012	27			
2013	31			
2014	180			
2015	402			

campo	porcentaje	observacion	del campo	Mediana	Endiarte	Rango
id_viaje	3	Concentrado en registros del Ecol de Operaciones		Valor atípico	Medio 54,2 Mediana 18	La media de duración de los viajes es influenciada por los valores extremos
activos_dueto	11	100% ocurre entre 10:00 y 20:00 en Eddy y Kennedy		hora pico	entre 6 y 8 de la mañana y tarde los viajes son de 43541	En horas de punta se debe tener una distribución y tener todos los días
direccion_via	11	Calculado fila y fila con los valores de dirección_dueto		valor atípico	valor atípico 402, valor atípico 402, valor atípico 402	En horas de punta se debe tener una distribución y tener todos los días
edad_usuario	10	Todos pertenecen a usuarios registrados entre 18 y 30 años				En horas de punta se debe tener una distribución y tener todos los días
costo	9	En un momento donde se ha estado generando algunos errores dentro de la recopilación de datos de los campos específicos a través de los datos de los usuarios, se han detectado				En horas de punta se debe tener una distribución y tener todos los días



Momento 4:

Repo alisson:

<https://github.com/nawallcarabali1365-ingenieriadedatos/ingenieria-de-datos-/tree/c1122ccced5e77c064b5ac783b4772dad1938772/corte%201/parcial%20ingenieria%20de%20datos%20corte1>

63 -> Alison Moten

Momento 4 · La reunión caótica

17 minutos | Corredor 4 | 25 puntos | Insumo: M4_transcripcion_kickoff.csv (Anexo C)

Te tocó ser el único de tu equipo en la reunión de kickoff. Nadie tomó acta ordenada. Solo quedó la transcripción. Con eso hay que arrancar el sprint.

4.1 Mapa de actores · 6 puntos

Clasifica a todos los actores que aparecen en la transcripción:

Actor	¿Stakeholder, usuario final o ambos?	Interés principal	Influencia
Gerente general	usuario final y stakeholder	llevar registro de los viajes y cuando factura la empresa	ALTA
Coordinador de OPe	stakeholder	tener la manera de consultar datos sobre los viajes y viajes	MEDIA
Desarrollador back	stakeholder	crear un programa con todos los requerimientos pedidos	ALTA
Líder producto	stakeholder	informarse sobre los quejas de los usuarios.	BAJA
Usuarios	usuario final	que la app les informe que lo bien está ahí y que no se ponga	ALTA

Además: identifica al actor que fue mencionado pero no estuvo en la reunión y explica qué riesgo genera esa ausencia. → El AREA JURIDICA FALTO → son los encargados del manejo de datos de los clientes y los permisos que otorgan, son importantes ya que estos nos permiten analizar tendencias de los clientes.

4.2 Extracción de requerimientos · 8 puntos

- Mínimo 4 requerimientos funcionales, redactados como «El sistema debe permitir...».
- Mínimo 3 requerimientos no funcionales, indicando la categoría: rendimiento, seguridad, usabilidad, disponibilidad o escalabilidad.
- Una frase de la transcripción que NO es un requerimiento —una queja, un deseo vago o una solución impuesta— reescrita como requerimiento verificable.

4.3 Historias de usuario · 11 puntos

Redacta tres historias de usuario, cada una para un rol distinto, en este formato:

Estructura	Contenido
Como <rol> quiero <acción> para <beneficio de negocio>	
Criterios de aceptación (Gherkin): Dado... / Cuando... / Entonces...	
Prioridad MoSCoW y justificación en una línea	

- Cada historia debe tener mínimo dos criterios de aceptación.
- Una de las tres debe ser una historia técnica del equipo de datos, no de la app.

entregable: mapa de actores, lista de requerimientos funcionales y no funcionales, y tres historias.

Anexo C · Transcripción de la reunión de kickoff

Archivo M4_transcripcion_kickoff.csv

#	Actor	Intervención
1	Marcela - Gerente General	Necesito ver en una sola pantalla cuántos viajes hacemos por día y cuánto facturamos. Ayer el inversionista me preguntó y no supe qué decir. Y por favor que cargue rápido, no como el sistema anterior que se demoraba tres minutos.
2	Julián - Coordinador de Operaciones	Lo mío es distinto. Yo necesito saber qué estaciones se quedan sin bicicletas antes de las 8 de la mañana, para mandar el camión a reponer. Si me avisa una hora antes, perfecto.
3	Julián - Coordinador de Operaciones	Ah, y yo actualizo un Excel todos los días a mano... ¡ojalá no me toque seguir haciéndolo.
4	Daniela - Líder de Producto	Los usuarios se quejan en las reseñas de que la app no muestra bicicletas disponibles en tiempo real.
5	Daniela - Líder de Producto	También quiero poder consultar el historial de viajes de un usuario cuando escriben a soporte, pero solo yo y el equipo de soporte deberíamos ver eso, ahí hay datos personales.
6	Andrés - Desarrollador backend	Yo les digo desde ya: háganlo en MongoDB, punto. Es lo que yo sé usar.
7	Marcela - Gerente General	Otra cosa, la semana pasada se cayó el sistema un domingo y perdimos toda la operación del día. Eso no puede volver a pasar.
8	Julián - Coordinador de Operaciones	Y a mí me sirve poder descargar un archivo con los viajes del mes para pasárselo al contador.
9	Daniela - Líder de Producto	Ojo que el mes entrante entramos en Medellín y en Cali. Vamos a triplicar el volumen de datos.
10	Marcela - Gerente General	Ah, y hablando de eso... el área jurídica dijo algo sobre protección de datos personales de los usuarios, pero no alcanzaron a venir hoy. Después les cuento.
11	Julián - Coordinador de Operaciones	Los usuarios de la bici, los ciudadanos, ellos qué... bueno, ellos solo quieren que la bici esté ahí y que la app no se caiga.


HISTORIAS DE USUARIOS

1 H001 → Registrar usuario

DESEAR como desarrollador, quiero que el sistema me permita registrar usuarios, para que estos tengan acceso al sistema.

- CA
- ☐ Ingresar cédula
 - ☐ Ingresar foto perfil
 - ☐ Ingresar rol
 - ☐ Mandar mensaje de error en caso de que no se ingrese algún dato correctamente
 - ☐ Mandar mensaje de aprobación cuando se haya registrado correctamente

PRIORIDAD → ALTA



RQF

001 → Ver Viajes → El sistema permite al usuario ver la cantidad de viajes por día

RQF → Registrar ganancias

003 → El sistema debe permitir ingresar las ganancias de la empresa por día

RQF 001 → Registrar usuario

El sistema debe permitir registrar el usuario y el tipo de usuario

RQF → Consultar disponibilidad Ciclos

004 → el sistema debe permitir ver cual es la disponibilidad de bikes en cada estacion

RQ NO F → El sistema debe cargar rapido → "cargar rapido"

RQ NO F → El sistema debe optimizar las ventas para triplicar el volumen → "Optimizar ventas"

RQ NO F → El sistema de evitar caídas para optimizar las operaciones. → "Evitar caídas"

los usuarios desean que la bici este ahí } consultar bikes disponibles

RQ004

los usuarios pueden verificar cuántos bikes hay en X sede.

Momento 5

Momento 5 · El muro de la arquitectura

25 minutos | Corredor 5 dibuja, el grupo asesora | 35 puntos | Insumos: M5_diccionario_datos.csv y M5_estaciones_maestro.csv

Llegó el comité técnico. No hay proyector. Hay una cartulina y marcadores. Tienen que dejar el diseño en la pared y sustentarlo de pie.

En medio pliego de cartulina, dividido en dos mitades claramente rotuladas, dibujen:

5.1 Mitad izquierda · Diagrama de clases (UML) · 15 puntos

- Mínimo 6 clases con atributos y tipos.
- Mínimo 2 métodos significativos por clase principal: métodos que hagan algo del negocio, no solo get y set.
- Multiplicidades en todas las relaciones: 1..1, 1..*, 0..*,
- Al menos una herencia o generalización y una composición o agregación, con la notación correcta.
- Visibilidad (+, -, #) en atributos y métodos.

5.2 Mitad derecha · Modelo conceptual para base de datos relacional · 15 puntos

- Entidades con sus atributos e identificador subrayado.
- Relaciones nombradas con verbo, con cardinalidad y participación (total o parcial).
- Resolver correctamente al menos una relación muchos a muchos.
- Marcar un atributo derivado y un atributo multivaluado con la notación adecuada.

5.3 Sustentación relámpago · 5 puntos

El corredor 5 tiene 90 segundos para responder frente al muro:

- ¿Qué diferencia hay entre lo que dibujaron a la izquierda y a la derecha? ¿Por qué no son el mismo diagrama? *no son el mismo diagrama ya que el de la izquierda contiene métodos y tipos de datos de los atributos y los de la derecha solo contienen el tipo de atributo y no contiene métodos.*
- Señalen una decisión de modelado que tomaron y que pudo haber sido distinta, y digan qué habrían perdido con la otra opción.
- ¿Dónde aterrizan en este modelo los datos que limpiaron en el momento 2? *En el momento 2 el viaje se proporciona a la entidad de Viaje (al revés de lo bajo)*

Coherencia: los evaluadores verificarán que las entidades del muro correspondan con los requerimientos del momento 4 y con los campos del momento 2. Un modelo bonito pero desconectado de la misión pierde puntos.


Entregable: cartulina firmada por los cinco corredores.


Evaluación

Momento	Puntos
1. Sala de servidores	15

Pregunta 3: id-viaje debe derivarse en la entidad usuario, id-usuario debe derivarse

En la clase usuario, estacion-origen debe derivarse en la entidad usuario al igual que estacion-destino, fecha-inicio derivada a la entidad Viaje al igual que fecha-fin, duracion-min derivada a Tarifa, costo a Viaje y edad-usuario derivada a





Repositorio Isabella: <https://github.com/isabellagalarzap-cmd/IngenieriadeDatos2026-2/tree/6d875987ea7b6083c2325bc7ae285abfa3d1a8e8/Parcial%201>